Pre-entrega Módulo 5 · RAG: el cerebro documental del agente

Alumna: Glorianna Alfonzo Jones · **Proyecto integrador:** Asistente de Calificación de Leads de **Sowe** (consultoría de software y automatizaciones) · **Workflows:** "M5 - Sowe RAG (Chat + Email + CRM + Slack + Conocimiento)" y "M5 - Sub-workflow RAG Sowe (buscar_manual_sowe)", n8n Cloud 2.42 · **Repositorio:** github.com/jonesg788/n8n-agente-leads (carpeta modulo5/)

1. Fuente de datos: LlamaParse (jerarquía de títulos y tablas en celdas)

Documento elegido: el Manual de Servicios, Políticas Comerciales y Preguntas Frecuentes de Sowe v1.0 (PDF de 4 páginas, 7 secciones, 5 tablas). Es la fuente oficial de lo que más preguntan los leads: servicios, pagos, cancelaciones, garantía y tiempos de soporte. **Limpieza:** se parseó con LlamaParse (modo Agente) y se curó a mano. Se eliminaron los pies de página repetidos, se unificó la jerarquía (# título, ## sección, ### subsección), las tablas HTML se pasaron a Markdown y se corrigió la tabla de SLA de la §5.3, que el primer parse había **inventado**.

3.1 Etapas de un proyecto

Etapa	Descripción	Participación del cliente
1. Diagnóstico	Reunión inicial sin cargo y relevamiento del proceso.	Explica el proceso y comparte ejemplos reales.
2. Propuesta	Sowe envía alcance, entregables, cronograma y presupuesto en un plazo de 5 días hábiles desde el diagnóstico.	Revisa y aprueba la propuesta por escrito.
3. Desarrollo	Construcción por iteraciones de 2 semanas con una demo al final de cada una.	Asiste a las demos y valida avances.
4. Pruebas y puesta en marcha	Pruebas con datos reales y pase a producción.	Firma el acta de aceptación.
5. Soporte	Garantía y, si se contrata, plan de soporte mensual.	Reporta incidentes por los canales

LlamaParse · Resultados: el título "3.1 Etapas de un proyecto" mantiene su jerarquía y la tabla se conserva como celdas (Etapa / Descripción / Participación del cliente).

5.3 Tiempos de respuesta según prioridad (SLA)

Prioridad	Definición	Primera respuesta	Resolución objetivo
Crítica	El sistema está detenido y afecta la operación del negocio.	2 horas hábiles (Plan Premium: 1 hora, 24 x 7)	8 horas hábiles
Alta	Una función importante falla, pero existe una alternativa manual.	4 horas hábiles	2 días hábiles
Media	Error menor que no impide trabajar.	1 día hábil	5 días hábiles
Baja	Consultas, dudas de uso o pedidos de mejora.	2 días hábiles	Se planifica con el cliente

LlamaParse · segundo parse: §5.3 con la tabla de SLA correcta (Crítica 2 h hábiles, Premium 1 h 24x7, resolución 8 h hábiles).

Hallazgo de calidad: el primer parse alucinó la tabla de la §5.3



5. Garantía y soporte

5.1 Garantía incluida

Todo proyecto incluye una garantía de 90 días corridos desde la firma del acta de aceptación. Durante la garantía, Sowe corrige sin costo cualquier error del desarrollo entregado (por ejemplo, un workflow que falla con datos válidos). La garantía no cubre cambios de alcance, errores causados por modificaciones que haga el cliente ni fallas o cambios de servicios de terceros (APIs, plataformas o proveedores externos).

5.2 Planes de soporte mensual

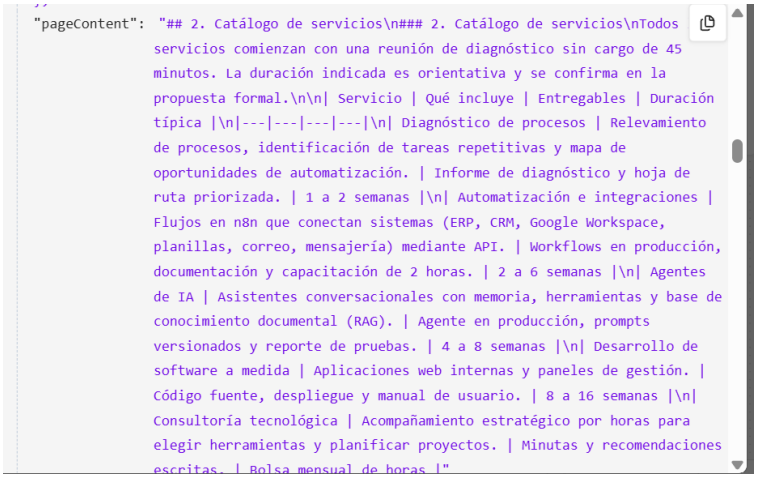
Característica	Plan Esencial	Plan Premium
Canal de atención	Email a soporte@sowe.example	Email y canal compartido de Slack
Horario	Lunes a viernes de 9:00 a 18:00	24 x 7 para incidentes críticos; resto en horario laboral
Horas de mejoras incluidas por mes	2 horas	6 horas
Monitoreo de workflows	Revisión semanal	Alertas automáticas en tiempo real
Reunión de seguimiento	Trimestral	Mensual

5.3 Tiempos de respuesta según prioridad (SLA)

Prioridad	Definición	Primera respuesta	Resolución objetivo
Crítica	El sistema está detenido y afecta la operación del negocio.	2 horas hábiles (Premium: 1 hora, 24 x 7)	8 horas hábiles
Alta	Una función importante falla, pero existe una alternativa manual.	4 horas hábiles	2 días hábiles
Media	Error menor que no impide trabajar.	1 día hábil	5 días hábiles
Baja	Consultas, dudas de uso o pedidos de mejora.	2 días hábiles	Se planifica con el cliente

Los tiempos se miden en horario de atención (sección 1.3), salvo los incidentes críticos del Plan Premium.

PDF original, §5.3: la fuente de verdad.



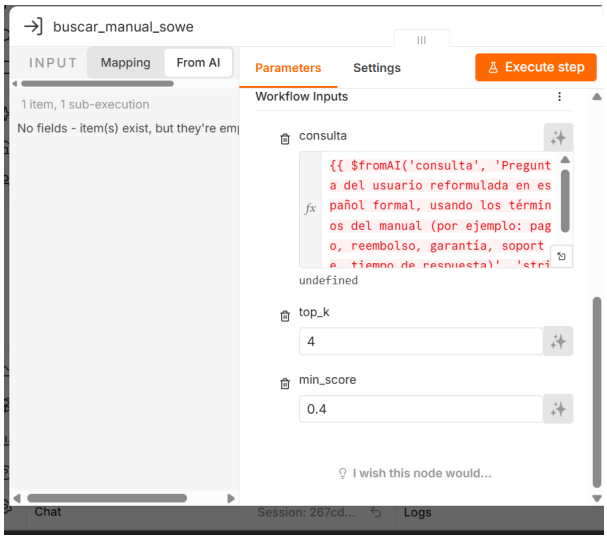
```
"pageContent": "## 2. Catálogo de servicios\n### 2. Catálogo de servicios\nTodos
servicios comienzan con una reunión de diagnóstico sin cargo de 45
minutos. La duración indicada es orientativa y se confirma en la
propuesta formal.\n\n| Servicio | Qué incluye | Entregables | Duración
típica |\n|---|---|---|---|\n| Diagnóstico de procesos | Relevamiento
de procesos, identificación de tareas repetitivas y mapa de
oportunidades de automatización. | Informe de diagnóstico y hoja de
ruta priorizada. | 1 a 2 semanas |\n| Automatización e integraciones |
Flujos en n8n que conectan sistemas (ERP, CRM, Google Workspace,
planillas, correo, mensajería) mediante API. | Workflows en producción,
documentación y capacitación de 2 horas. | 2 a 6 semanas |\n| Agentes
de IA | Asistentes conversacionales con memoria, herramientas y base de
conocimiento documental (RAG). | Agente en producción, prompts
versionados y reporte de pruebas. | 4 a 8 semanas |\n| Desarrollo de
software a medida | Aplicaciones web internas y paneles de gestión. |
Código fuente, despliegue y manual de usuario. | 8 a 16 semanas |\n|
Consultoría tecnológica | Acompañamiento estratégico por horas para
elegir herramientas y planificar proyectos. | Minutas y recomendaciones
escritas. | Bolsa mensual de horas |"
```

Chunk ya indexado en n8n (después de curar): la tabla del Catálogo queda entera dentro de un único fragmento, con su título.

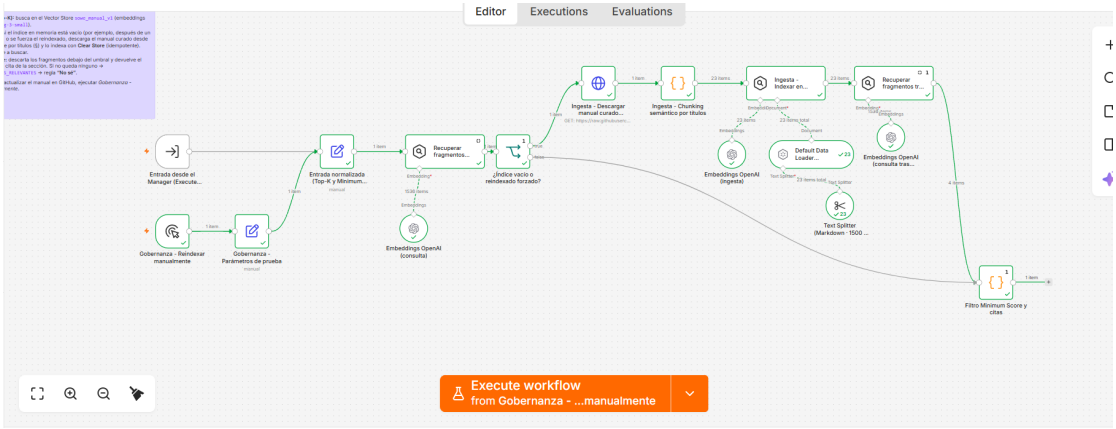
```
Primer parse (modo Agente) · §5.3 · tabla INVENTADA, que no existe en el PDF:
| Prioridad   | Incidente                          | Inicio   | Resolución |
| Critico     | El sistema no responde             | 15 min   | 2 horas    |
| Alto        | Un flujo de trabajo no se ejecuta  | 30 min   | 4 horas    |
| Bajo        | Un flujo ... más lento de lo habitual | 24 horas | 3 días   |
| Informático | Un flujo de trabajo no se ejecuta  | 48 horas | 14 días    |
```

Por qué importa: si se hubiera indexado sin revisar, el agente le habría prometido a un cliente “respuesta en 15 minutos”. Al parsear de nuevo, la §5.3 salió correcta: **LlamaParse en modo Agente no es determinista**. Por eso el plan de gobernanza (pieza 5) exige comparar cada tabla contra el PDF antes de indexar. **Cambio de arquitectura justificado:** el índice de LlamaCloud (Index / carpetas) requiere plan pago (Starter o superior). Por eso se usó LlamaParse (plan gratuito) solo para el parseo, y el almacén vectorial se armó en n8n (Simple Vector Store + embeddings de OpenAI text-embedding-3-small). El Markdown curado vive versionado en GitHub y es la única fuente que se indexa.

2. Herramienta de recuperación: Top-K y Minimum Score



Nodo buscar_manual_sowe (Call n8n Workflow Tool) conectado al Manager: llama al sub-workflow RAG publicado. consulta la completa la IA ($fromAI) y los parámetros son fijos: top_k = 4 y min_score = 0.4.



Sub-workflow RAG: Entrada normalizada → Recuperar fragmentos (Top-K) del Vector Store sowe_manual_v1 → si el índice está vacío, se re-indexa solo (descarga del Markdown curado → chunking por títulos → 23 fragmentos) → Filtro Minimum Score y citas. En la prueba recupera 4 fragmentos y devuelve 1 resultado.

Parámetro	Valor	Justificación
Chunking	1 fragmento por subsección (## / ###), máx. 1.500 caracteres, overlap 150	Cada política queda completa en un solo fragmento y las tablas no se parten. Con la sección como metadata se puede citar "§5.3". Resultado: 23 fragmentos de unos 100 a 350 tokens.
Top-K	**4**	Las respuestas del manual viven casi siempre en 1 o 2 subsecciones. Con 4 hay margen cuando la pregunta es coloquial ("la guita", "cripto") y el mejor fragmento no sale primero, y el contexto queda acotado a unos 1.000 tokens. Top-K 8 duplicaría el costo y sumaría ruido; Top-K 1 o 2 arriesga perder la sección correcta.
Minimum Score	**0.40** (similitud coseno)	Es el umbral de corte: los fragmentos por debajo se descartan antes de llegar al modelo, y si no queda ninguno la herramienta devuelve SIN_FRAGMENTOS_RELEVANTES y se activa el "No sé". Se eligió bajo para priorizar la cobertura: los aciertos midieron entre 0.517 y 0.697 (pieza 4).
Costo medido	4.409 a 5.207 tokens por turno	Incluye el System Prompt del Manager (unos 2.600 tokens), la llamada a la herramienta y la respuesta. El RAG suma unos 2.000 tokens: precisión con un costo controlado.

Balance precisión / costo: 4 fragmentos de una subsección cada uno dan contexto suficiente y citable sin inflar la ventana. El Minimum Score evita gastar tokens (y alucinar) cuando la pregunta no está en el manual. Como el ruido semántico del manual mide entre 0.45 y 0.55, el umbral no se sube más: la segunda barrera es la regla "No sé" del prompt (ver el análisis de la pieza 4).

3. System Prompt RAG: citas obligatorias y regla “No sé”

System Message del nodo **Manager - Agente LLM (gpt-4o)**. Se agregó la sección 10 y se ajustaron las secciones 6 y 7 del prompt de M3/M4 (antes no podía dar plazos ni condiciones; ahora puede, pero solo si salen del manual y citando la sección).

```
# 10. BASE DE CONOCIMIENTO DOCUMENTAL (RAG)
Herramienta: buscar_manual_sowe (Manual de Servicios,
Políticas Comerciales y Preguntas Frecuentes de Sowe v1.0).
- OBLIGATORIO: en este mismo turno, llama a
buscar_manual_sowe ANTES de escribir respuesta_usuario.
Nunca respondas "No sé" sin haber llamado antes a la
herramienta.
- Antes de responder CUALQUIER pregunta sobre servicios,
metodología, presupuestos, pagos, cancelaciones, garantía,
soporte, tiempos de respuesta, horarios, descuentos,
confidencialidad, propiedad intelectual o herramientas de
Sowe, llama a buscar_manual_sowe con la pregunta reformulada
en español formal.
- Basa respuesta_usuario 100% en los fragmentos devueltos.
No completes con conocimiento general, no supongas y no
mezcles datos de secciones distintas si no se relacionan.
- Cita siempre la fuente al final de respuesta_usuario con
este formato: (Fuente: Manual de Servicios Sowe v1.0,
§número y título de la sección).
```

Sección 10 (1/2): llamada OBLIGATORIA a buscar_manual_sowe antes de responder, respuesta 100% basada en los fragmentos y cita con formato fijo (Fuente: Manual de Servicios Sowe v1.0, §número y título).

```
- REGLA "NO SÉ": si la herramienta devuelve
SIN_FRAGMENTOS_RELEVANTES o si los fragmentos no contienen
el dato exacto que se pregunta, respuesta_usuario debe
empezar textualmente con "No sé" y continuar así: "No sé:
esa información no figura en la documentación oficial de
Sowe. Un consultor puede ayudarle con esa consulta." No
intentes adivinar.
- No uses la herramienta para saludos, para registrar leads
ni para temas fuera de alcance.
```

Sección 10 (2/2): REGLA “NO SÉ”: si la herramienta devuelve SIN_FRAGMENTOS_RELEVANTES o los fragmentos no contienen el dato exacto, la respuesta empieza textualmente con “No sé: esa información no figura en la documentación oficial de Sowe…”.

```
# 6. RESPUESTA AL USUARIO (campo respuesta_usuario)
- Si conoces el nombre del usuario, salúdalo por su nombre.
- NUEVO_LEAD: una oración breve de recepción (el sistema la
completa con el resultado de los Workers).
- DATOS_INCOMPLETOS: indica solo los datos que todavía
faltan; no vuelvas a pedir los que ya entregó.
- CONSULTA_SERVICIOS: responde con la información del Manual
de Sowe obtenida con la herramienta buscar_manual_sowe
(máximo 100 palabras) y cita la fuente; si faltan datos de
contacto, invita a enviarlos.
- ESCALAR_HUMANO: informa que un consultor de Sowe revisará
el caso y se comunicará a la brevedad.
- FUERA_DE_ALCANCE: indica con cortesía que solo puedes
ayudar con consultas sobre los servicios de Sowe.

# 7. RESTRICCIONES (lo que NO tienes permitido hacer)
- NO das precios ni cotizaciones; NO agendas reuniones.
Plazos, condiciones y políticas solo si figuran en los
fragmentos del manual, citando la sección.
```

Secciones 6 y 7 ajustadas: CONSULTA_SERVICIOS responde con el manual y cita la fuente. Precios y cotizaciones siguen prohibidos.

Configuración complementaria: el modelo del Manager (gpt-4o) pasó de **Response Format = JSON** a **Text**, porque en modo JSON el agente no llamaba a la herramienta (iteración 1). La salida sigue siendo JSON y la valida el nodo Manager - Triaje y Planificación, igual que en M3.

4. Validación: batería de 5 preguntas ciegas

Preguntas redactadas como las haría un cliente (lenguaje coloquial, sin las palabras del manual), cada una en una sesión nueva del chat. La 5 es una pregunta trampa cuya respuesta no está en el documento. **Criterio de acierto:** dato correcto según el PDF original, con la cita de la sección (o "No sé" cuando corresponde) y sin datos inventados.

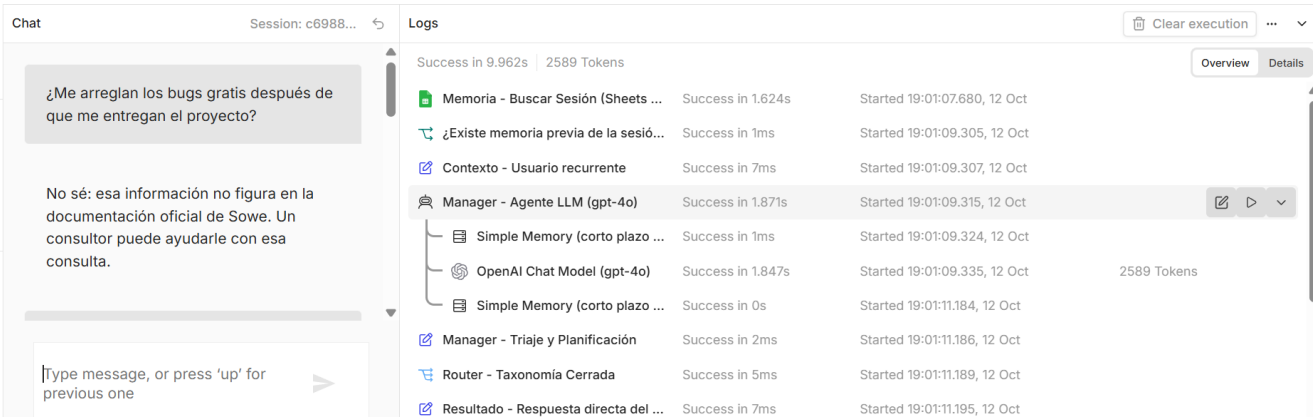
#	Pregunta ciega	Esperado	Consulta generada por la IA → fragmento top-1 (score)	Respuesta del agente	Resultado
1	¿Me arreglan los bugs gratis después de que me entregan el proyecto?	§5.1 · 90 días sin costo	"garantía y soporte post-entrega de proyectos" → §5.1 (0.697)	90 días corridos desde el acta, sin costo, con las exclusiones. Cita §5.1.	**Correcta**
2	Si se me cae todo el sistema un martes, ¿en cuánto me responden?	§5.3 · Crítica: 2 h hábiles / 8 h	"tiempo de respuesta en caso de caída del sistema un martes" → §5.3 (0.548)	2 h hábiles de primera respuesta y 8 h hábiles de resolución, horario de atención, Premium 24x7. Cita §5.3.	**Correcta** (omite el "1 hora" del Premium)
3	¿Les puedo pagar con cripto?	§4.2 · No	"formas de pago con criptomonedas" → §4.2 (0.517)	No se aceptan; transferencia, Payoneer o Wise. Cita §4.2.	**Correcta**
4	Si me arrepiento antes de que arranquen a programar, ¿me devuelven la guita?	§4.3 · 50% del anticipo	"reembolso por cancelación antes de iniciar programación" → §4.3 (0.644)	Se devuelve el 50% del anticipo; el 40% no es reembolsable una vez iniciado el desarrollo. Cita §4.3.	**Correcta**
5	¿Cuántos empleados tiene Sowe?	No figura → "No sé"	"cantidad de empleados en Sowe" → Datos del documento (0.543)	"No sé: esa información no figura en la documentación oficial de Sowe. Un consultor puede ayudarle…"	**Correcta**

Métrica	Iteración 1	Iteración 2 (final)
Precisión de respuesta (aciertos / 5)	0 / 5 = **0%**	5 / 5 = **100%**
Herramienta invocada	0 / 5	5 / 5
Sección correcta en el top-1 (preguntas 1 a 4)	n/a	4 / 4
Respuestas con cita de fuente (preguntas 1 a 4)	0 / 4	4 / 4
Rechazo correcto con "No sé" (pregunta 5)	Sí (por motivos equivocados)	Sí
Precisión de los fragmentos (útiles / recuperados), prueba de "garantía"	n/a	1 / 4 = 25% (3 de ruido entre 0.45 y 0.48)

Análisis crítico de los fallos

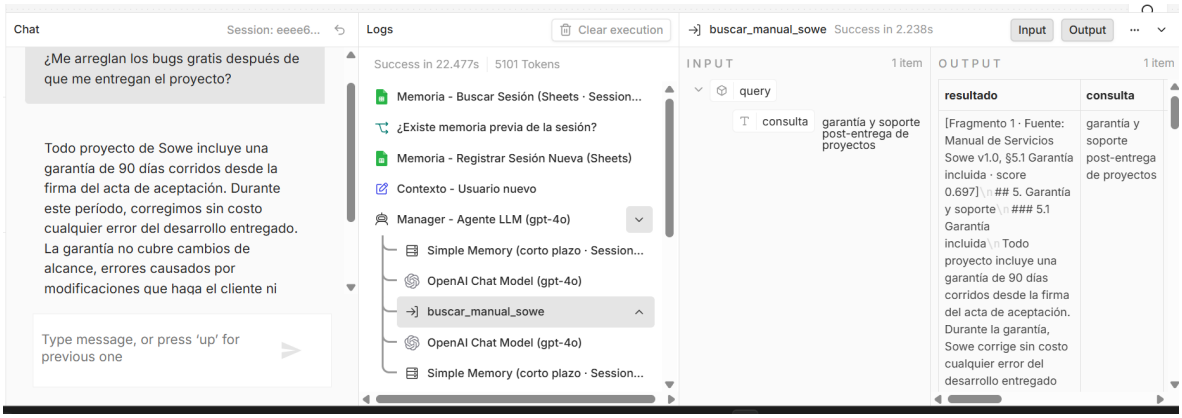
Fallo detectado	Causa raíz	Corrección aplicada
Iteración 1: respondió "No sé" a todo, incluso a lo que sí está en el manual.	El modelo estaba en Response Format = JSON: así el agente nunca emitía la llamada a la herramienta y, sin fragmentos, aplicaba la regla "No sé".	Response Format → Text, más una línea OBLIGATORIO en la §10 del prompt (llamar a la herramienta antes de responder).
La herramienta se llamaba pero devolvía "Workflow is not active and cannot be executed".	En n8n 2.x un sub-workflow solo se puede llamar si está publicado, y publicar el M5 activaría el Gmail Trigger.	Se separó el RAG en un sub-workflow propio, sin triggers externos, publicado. Además se re-indexa solo si el índice en memoria está vacío.
"Cannot embed empty or undefined text".	Al cambiar el workflow destino, n8n borró la expresión $fromAI del campo consulta.	Se restauró $fromAI('consulta', …) con una descripción que pide reformular en español formal.

Fallo detectado	Causa raíz	Corrección aplicada
Ruido semántico: en la pregunta 5 un fragmento irrelevante midió 0.543, más que el acierto de la pregunta 3 (0.517).	En un manual corto y homogéneo todos los fragmentos se parecen. El Minimum Score solo no separa lo relevante de lo irrelevante.	Se mantiene 0.40, porque subirlo a 0.55 perdería las preguntas 2 y 3. El "No sé" lo garantiza la regla del prompt ("si los fragmentos no contienen el dato exacto"). Mejora pendiente: no indexar el bloque "Datos del documento".
Pregunta 2 incompleta: no aclaró la "1 hora 24x7" del Plan Premium.	El modelo resumió la celda de la tabla.	Aceptable (no inventa), pero se suma al banco de pruebas. Si se repite, agregar al prompt "incluye las variantes por plan".
Riesgo de origen: tabla de SLA alucinada en el primer parse.	LlamaParse en modo Agente no es determinista.	Curaduría manual contra el PDF y validación obligatoria de las tablas en cada actualización (pieza 5).

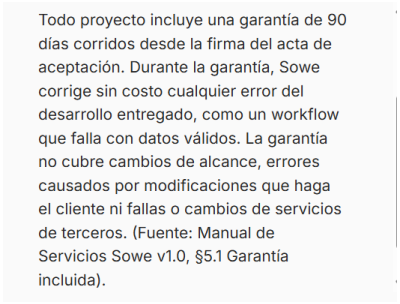


Iteración 1 (antes de corregir): el Manager no invoca ninguna herramienta (en los logs solo aparecen Memory y Chat Model) y responde "No sé".

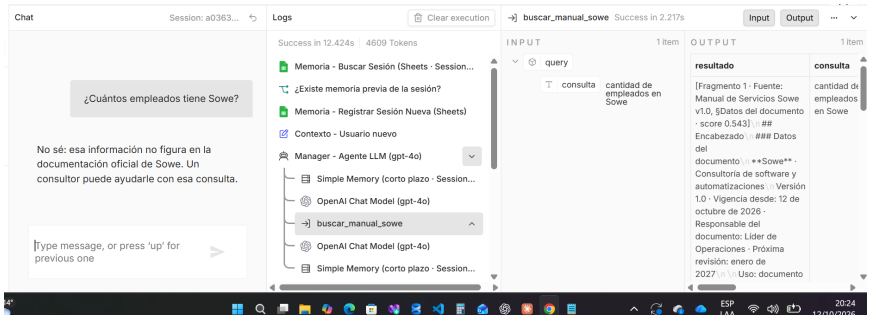
Evidencia de la iteración 2



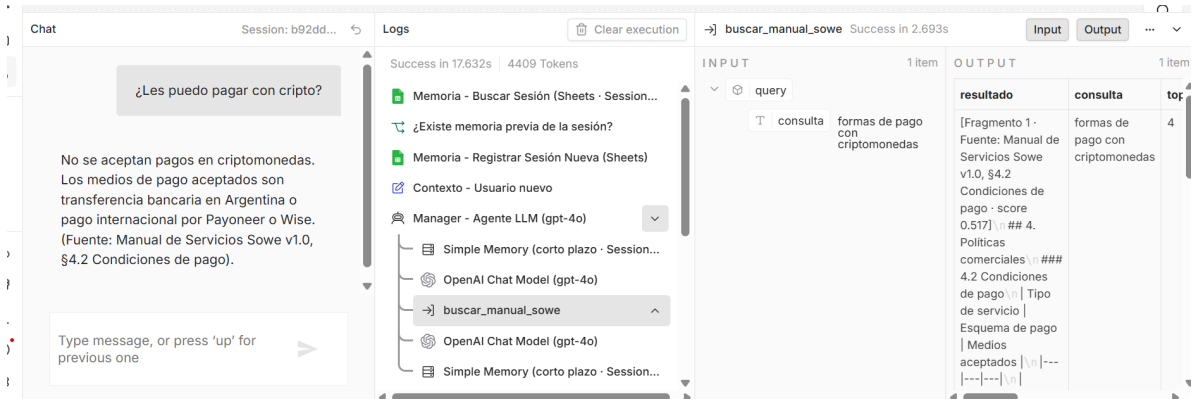
Pregunta 1: el Manager llama a buscar_manual_sowe (entrada: "garantía y soporte post-entrega de proyectos"), y la salida trae el Fragmento 1 de la §5.1 con score 0.697.



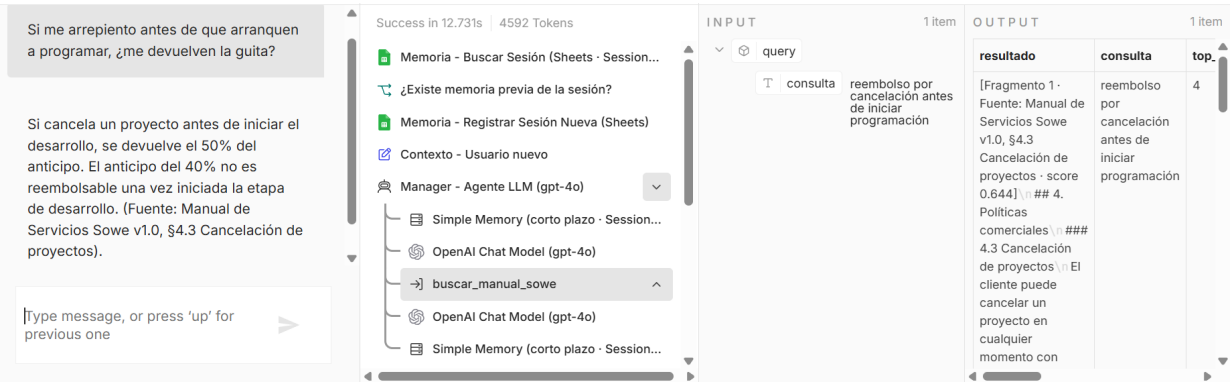
Pregunta 1: final de la respuesta con la cita (Fuente: Manual de Servicios Sowe v1.0, §5.1 Garantía incluida).



Pregunta 5 (trampa): la herramienta trae "Datos del documento" (0.543), pero no contiene el dato, así que la respuesta es "No sé...".



Pregunta 3: "No se aceptan pagos en criptomonedas..." con cita de la §4.2 (score 0.517).



Pregunta 4: devolución del 50% del anticipo con cita de la §4.3 (score 0.644).

5. Plan de gobernanza de la base de conocimiento

La documentación desactualizada es la mayor fuente de alucinaciones de un RAG: el agente repite con seguridad lo que diga el índice. Este plan define quién custodia la verdad, cada cuánto se revisa y cómo se reemplaza o elimina un documento.

Componente	Definición para Sowe
Responsable (owner)	**Líder de Operaciones**: custodia la veracidad del manual, aprueba cada versión y avisa formalmente al responsable técnico (Asesor de IA). El **Asesor de IA** parsea, cura, re-indexa y corre las pruebas. Los cambios comerciales (precios, pagos, descuentos) requieren además el visto bueno del área comercial.
Frecuencia de revisión	**Mensual** (primer día hábil): §2 Catálogo de servicios y §4 Políticas comerciales (pagos, cancelación, descuentos de la §7.5), que son lo que más cambia. **Trimestral**: §5 Garantía, soporte y SLA, §6 Requisitos técnicos, §4.4 y §4.5 (propiedad intelectual y datos personales) y §7 FAQ. Próxima: enero de 2027 (figura en el manual). **Extraordinaria**: dentro de las 48 h de cualquier cambio de política, de un servicio nuevo o discontinuado, o de una alerta de calidad.
Procedimiento de actualización	1) Editar el documento maestro y subir la versión (v1.0 → v1.1, con la fecha de vigencia). 2) Parsear con LlamaParse. 3) Comparar **cada tabla y cifra** contra el PDF (lección de la §5.3 alucinada). 4) Curar el Markdown (títulos ##/###, sin pies de página) y hacer commit en GitHub con el detalle del cambio. 5) Ejecutar Gobernanza - Reindexar manualmente en el sub-workflow: Clear Store = ON, así nunca conviven dos versiones. 6) Batería de verificación.
Verificación de calidad	**Batería de 5 preguntas ciegas** después de cada re-indexado, que incluye siempre 1 pregunta trampa ("No sé") y al menos 1 sobre la sección modificada. Umbral de aprobación: 5/5 con la cita de sección correcta. Si sale menos de 5/5 se vuelve a la versión anterior (commit previo + re-indexar) hasta corregir. Los resultados se registran (fecha, versión, scores).
Señales de alerta	Respuestas vagas o sin cita; "No sé" ante temas que sí están en el manual; datos que contradicen lo que dice el equipo comercial; reclamos de clientes; scores top-1 por debajo de 0.50 en preguntas habituales; un fragmento vencido o sin sección en los resultados.

Criterios para eliminar o reemplazar documentos

Situación	Acción	Criterio
Cambia una política, un plazo o una condición	**Reemplazar** (versión nueva)	La versión vieja se sobrescribe en el índice (Clear Store) y queda solo en el historial de GitHub para auditoría. Nunca dos versiones activas.
Se discontinúa un servicio o se deroga una política	**Eliminar** la sección	Se quita del Markdown y se re-indexa. Si los clientes todavía preguntan por eso, se agrega una FAQ con la respuesta vigente ("ya no ofrecemos…").
El documento perdió vigencia (la fecha de próxima revisión pasó sin revisión)	**Reemplazar o bloquear**	Si no se revisa dentro de los 15 días de la fecha prevista, el Líder de Operaciones decide si se revalida o se retira del índice.
Contenido contradictorio o duplicado	**Unificar**	Una sola fuente de verdad por tema. Se conserva la versión aprobada más reciente y la otra se elimina.
Fragmentos sin valor de respuesta (encabezados, metadatos, pies de página)	**No indexar**	Generan ruido en la recuperación (en la pregunta 5, el bloque "Datos del documento" midió 0.543). Se excluyen en el chunking.
Datos personales o confidenciales de clientes	**Eliminar de inmediato**	La base de conocimiento solo contiene información institucional pública para clientes (Ley 25.326).

Riesgo técnico gestionado: el Simple Vector Store vive en la memoria de n8n y se pierde si la instancia se reinicia. El sub-workflow lo detecta (índice vacío) y re-indexa solo desde el Markdown versionado en GitHub, así el agente nunca queda sin conocimiento. Para producción se recomienda migrar a un almacén persistente (LlamaCloud Index con plan pago, Supabase/pgvector o Pinecone) sin cambiar la herramienta ni el prompt.