Pre-entrega Módulo 9 · Plan de gobernanza, gestión y monitoreo financiero de IA

Alumna: Glorianna Alfonzo Jones · **Sistema:** agente de Sowe (chat + email + voz, RAG, supervisor AI-as-a-Judge y dashboard del M8) · **Repositorio:** github.com/jonesg788/n8n-agente-leads (carpeta modulo9/) · **Supuestos:** 1.000 ejecuciones/mes (≈ 400 interacciones de unos 2,5 mensajes), hora hombre cargada US$ 10, arquitectura recomendada en el M8 (agente gpt-4o-mini + juez gpt-4o).

Dimensión 1 · Planificación financiera y economía del token

KPIs de negocio para la dirección

KPI	Definición y fórmula (dashboard Sheets)	Baseline	Meta	Medido hoy (M8)
Tasa de resolución autónoma	Ejecuciones resueltas sin humano / total. =CONTAR.SI(HITL;"NO")/CONTARA(HITL)	0%	≥ 60% de las consultas informativas	11/11 veredictos sin HITL en el test A/B
Horas operativas ahorradas	Σ (minutos manuales − minutos de revisión) × volumen / 60	122,8 h/mes manuales	≥ 80 h/mes	95,5 h/mes (proyección)
Satisfacción del usuario (CSAT)	Botón "¿Le sirvió? Sí / No" al final de cada respuesta → columna CSAT. =PROMEDIO(CSAT)	No medida	≥ 85% de "Sí"	Diseño (M10/M11)
Reducción de errores	Precisión vs. ground truth en la batería ciega mensual + errores manuales de CRM evitados	≈ 30% de leads incompletos	≥ 95% de precisión y ≥ 98% de registros completos	100% de precisión final (10/10, M8)
Costo por resolución	TCO mensual / ejecuciones resueltas	≈ US$ 3,07 por consulta manual	< US$ 0,15	US$ 0,096 (TCO total / 1.000)

ROI contra el baseline manual (una fila por tarea automatizada)

Tarea automatizada	Quién	Volumen/ mes	Antes	Después	h antes	h después	h ahorradas	Ahorro/mes
Calificar el lead, cargarlo en el CRM y avisar al equipo	Ejecutiva comercial	120 leads	25 min	3 min	50,0	6,0	44,0	US$ 440
Responder consultas de servicios y políticas	Ejecutiva comercial	80 consultas	10 min	2 min	13,3	2,7	10,7	US$ 107
Clasificar correos de soporte y redactar la respuesta	Analista de soporte	200 correos	12 min	4 min	40,0	13,3	26,7	US$ 267
Analizar reclamos y pedidos de reembolso (HITL con evidencia)	Líder de Operaciones	10 casos	45 min	20 min	7,5	3,3	4,2	US$ 42
Reporte semanal de leads y conversión por canal	Líder de Operaciones	4 reportes	180 min	30 min	12,0	2,0	10,0	US$ 100
Total					**122,8**	**27,3**	**95,5**	**US$ 955**

"Después" = el tiempo humano que queda: revisar leads calientes, aprobar borradores y decidir los casos HITL con la evidencia ya preparada.

Caso de negocio	Valor
Ahorro mensual de labor (95,5 h × US$ 10)	US$ 955
TCO mensual (tabla siguiente)	US$ 96,49
Beneficio neto mensual	**US$ 859**
ROI mensual = (ahorro − TCO) / TCO	**890%**
Inversión única de implementación (60 h × US$ 25/h)	US$ 1.500
Payback	**1,7 meses**
Absorción de picos (×3 de demanda, por ejemplo por una campaña)	+2.000 ejecuciones ≈ +US$ 14,42 en tokens, frente a contratar personal temporal (≈ US$ 800/mes) o perder leads por demora

Matriz de costo total de operación (TCO mensual)

Componente	US$/mes	Base del cálculo
Tokens LLM: agente gpt-4o-mini + juez gpt-4o (100% de las ejecuciones)	US$ 7,21	M8: US$ 0,0072 por ejecución × 1.000
Embeddings RAG (text-embedding-3-small, US$ 0,02 por millón de tokens)	US$ 0,01	≈ 1.000 consultas × 30 tokens: costo despreciable
Voz: Whisper (≈ 150 notas × 0,3 min × US$ 0,006/min)	US$ 0,27	Canal Telegram (M6)
Voz: ElevenLabs (≈ 150 respuestas × 200 caracteres = 30.000 caracteres)	US$ 5,00	Plan Starter (referencia de lista a validar)
Orquestación: n8n Cloud	US$ 24,00	Plan Starter (referencia de lista a validar). Pasar a Pro si los sub-workflows superan la cuota
LlamaParse, HubSpot CRM, Slack, Google Sheets	US$ 0,00	Planes gratuitos / herramientas ya existentes
Mantenimiento y gobernanza (6 h/mes: batería ciega, prompts, re-indexado)	US$ 60,00	Costo oculto: tiempo humano
TCO mensual total	**US$ 96,49**	Costo por ejecución: US$ 0,096
TCO optimizado (evaluación selectiva del juez)	**US$ 92,27**	Juez en el 100% de las acciones sensibles (≈ 20%) + muestreo del 20% del resto → el juez corre en ≈ 36% de las ejecuciones
Referencia: arquitectura A (gpt-4o) en los tokens	US$ 18,82	M8: US$ 0,0188 por ejecución. B ahorra US$ 11,61/mes

Los precios de lista de n8n y ElevenLabs son una referencia y se validan antes del despliegue. Los tokens provienen del registro real del M8 (estimados por caracteres).

Estrategias no técnicas de contención del gasto

Estrategia	Cómo se aplica en Sowe	Impacto
Acotar el contexto	RAG con Top-K 4 y Min Score 0.40 (M5) en lugar de mandar el manual entero. Resumen consolidado en lugar del historial completo (M3). Ventana de memoria de 6 a 10 turnos	Prompt chico y estable
Modelo según la tarea	gpt-4o-mini para responder; gpt-4o solo como juez (A/B del M8)	−62% de costo por ejecución
Topes de salida	maxTokens 400 (agente) / 120 (voz) / 400 (juez); 200 caracteres en voz; maxIterations 4	Costo por respuesta acotado
Evaluación selectiva	El juez solo en acciones sensibles + muestreo aleatorio	−59% en tokens (US$ 7,21 → US$ 2,99)
Prompt caching	Bloques fijos (manual completo, rúbrica del juez, System Prompt) al inicio del prompt para que se cacheen (ver la tabla siguiente)	Hasta −90% en los tokens cacheados

Prompt caching: análisis de proveedores

Proveedor	Cómo funciona	Precio del bloque cacheado	Aplicación a Sowe
Anthropic (Claude)	Explícito: marca cache_control en el bloque fijo. Mínimo 512 tokens en los modelos actuales. TTL de 5 min (renovable con cada uso) o de 1 h. Máximo 4 marcas por request	Lectura ≈ 0,1× el precio de input. Escritura 1,25× (5 min) o 2× (1 h). Sonnet 5.5: US$ 2 input / US$ 0,20 lectura de caché por millón de tokens	Manual curado (≈ 2.800 tokens) en el system prompt de un juez o un agente Claude: sin caché, 1.000 × 2.800 × US$ 2/M = US$ 5,60; con caché (≈ 90% de aciertos) ≈ US$ 1,20 → **−79%**
OpenAI (stack actual)	Automático para prefijos de 1.024 tokens o más, sin configuración	Descuento sobre los tokens de input cacheados (según la documentación vigente de OpenAI)	Ordenar los prompts: primero lo fijo (rúbrica, reglas) y al final lo variable (pregunta, contexto). Hoy el prompt del agente tiene ≈ 300 tokens (no llega al mínimo); el del juez sí aprovecha
Regla de diseño	Cualquier cambio en el prefijo invalida la caché	—	No poner fechas, IDs ni el traceId dentro del bloque fijo: van al final del mensaje

Control preventivo de API keys: separación física de entornos

Entorno	Llave / proyecto	Límite	Uso
DEV (pruebas, A/B, fault injection)	OpenAI Project “sowe-dev” (key propia) · workspace Claude “sowe-dev” · ElevenLabs key DEV con cuota de créditos	**US$ 5/mes** (OpenAI) y **US$ 5/mes** (Claude), con alertas al 50% y al 80%	Solo workflows M8 o pruebas; credencial n8n “OpenAI DEV ($5)”
PROD	OpenAI Project “sowe-prod” · workspace “sowe-prod”	US$ 25/mes (≈ 2,5 veces el TCO de tokens) con alerta al 80%	Workflows publicados (M6/M8); credencial “OpenAI PROD”
Barreras en el lienzo	maxIterations 4 · Retry On Fail ≤ 2 · contador de reintentos del juez (máx. 2) · Loop de 1 corrida a la vez · Timeout del workflow	—	Neutralizan bucles lógicos aunque falle el límite del proveedor

Hoy hay varias credenciales de OpenAI en n8n (OpenAI account 6 a 10). Acción: consolidarlas en dos (DEV y PROD), revocar las demás y no reutilizar la llave PROD en pruebas.

Dimensión 2 · Logs estructurados y trazabilidad (traceId)

Dashboard operativo: la tabla QA_Veredictos del M8 con la columna traceId

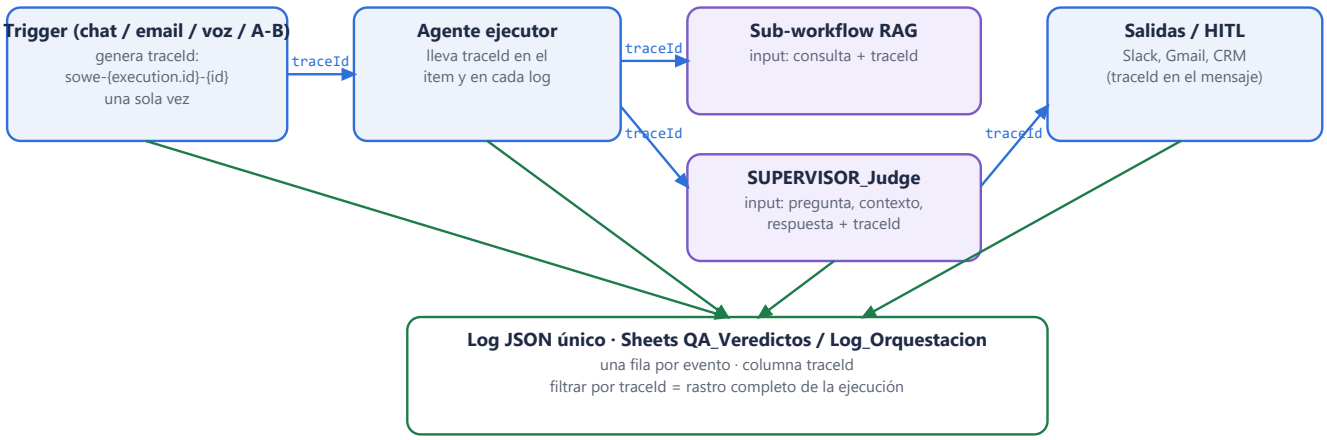
Se reutiliza la pestaña **QA_Veredictos** de Google Sheets (alimentada por n8n en cada veredicto). Se agrega la columna **traceId** = `sowe-{execution.id}-{ID_Corrida}`. Con ella, todas las filas de una misma conversación (intentos, veredictos y decisión humana) se filtran juntas.

traceId	Arq.	Int.	Exact.	Veredicto	HITL	Tokens	Coste USD	Lat. s
sowe-114-A1	A	1	5	ACEPTADO	NO	5497	0,015978	5,3
sowe-114-A2	A	1	5	ACEPTADO	NO	5662	0,016495	4,4
sowe-114-A3	A	1	5	CORREGIR	NO	4349	0,01244	4
sowe-114-A3	A	2	5	ACEPTADO	NO	4475	0,02542	11,2
sowe-114-A4	A	1	5	ACEPTADO	NO	5339	0,015297	3,9
sowe-114-A5	A	1	5	ACEPTADO	NO	7527	0,020925	5,3
sowe-114-B1	B	1	5	ACEPTADO	NO	5769	0,008267	3,8
sowe-114-B2	B	1	5	ACEPTADO	NO	5458	0,007849	4
sowe-114-B3	B	1	5	ACEPTADO	NO	4373	0,006407	3,5
sowe-114-B4	B	1	5	ACEPTADO	NO	4261	0,006251	3,6
sowe-114-B5	B	1	5	ACEPTADO	NO	5033	0,007282	4,4
sowe-139-QA6	QA	1	1	RECHAZADO	NO	4788	0,00696	6

Datos reales del M8 (ejecuciones 114 y 139). **sowe-114-A3** agrupa los 2 intentos del self-healing; **sowe-139-QA6** es la prueba HITL.

Panel (fila de resumen en Sheets)	Fórmula
Ejecuciones totales	=CONTARA(UNICOS(traceId))
Tasa de resolución autónoma	=CONTAR.SI(HITL;"NO")/CONTARA(HITL)
Precisión vs. ground truth	=CONTAR.SI(Correcto_GroundTruth;"SI")/CONTARA(Correcto_GroundTruth)
Costo mensual acumulado / proyección	=SUMA(Costo_USD) · =PROMEDIO(Costo_USD)*1000
Errores por categoría	Tabla dinámica: filas = Categoria_Error, valores = CONTAR(traceId)

Cómo viaja el traceId por los sub-workflows



El traceId se crea una sola vez en el trigger y se pasa **de forma explícita** como input en cada Execute Workflow (RAG, Juez, Workers W1/W2) y en cada mensaje de Slack o Gmail. Ningún sub-workflow genera el suyo.

Esquema del log JSON máquina-procesable (un objeto por evento)

```
{
  "traceId": "sowe-114-A3",
  "spanId": "judge-2",
  "parentSpanId": "agent-2",
  "timestamp": "2026-10-13T18:10:05-03:00",
  "env": "prod",
  "workflow": "M8 - SUPERVISOR_Judge",
  "nodeName": "Juez - Auditor de calidad (gpt-4o · JSON Schema)",
  "nodeType": "llm_judge",
  "model": "gpt-4o",
  "systemPromptSnapshot": {"id": "judge-prompt", "version": "v1.1", "sha256": "9f2c…e41a"},
  "toolName": "buscar_manual_sowe",
```

```
  "toolInput": {"consulta": "formas de pago con criptomonedas"},
  "toolOutput": {"fragmentos_usados": 1, "scores": "4.2 Condiciones de pago = 0.517", "resultado_truncado": "[Fragmento 1 ·
§4.2]…"},
  "output": {"estado_veredicto": "ACEPTADO", "exactitud_factual": 5, "categoria_error": "NINGUNO"},
  "confidenceScore": 0.95,
  "tokens": {"input": 2310, "output": 150},
  "costUsd": 0.0073,
  "latencyMs": 2100,
  "hitl": false,
  "piiRedacted": true
}
```


Campo	Para qué sirve en una auditoría
traceId (+ spanId / parentSpanId)	Reconstruye la cadena completa: trigger → agente → herramienta → juez → salida
timestamp	ISO 8601 con zona horaria. Ordena los eventos y mide latencias
nodeName	Qué nodo actuó (agente, herramienta, juez, Switch, HITL)
toolOutput	Qué evidencia vio el modelo (fragmentos RAG, truncados y sin datos personales)
systemPromptSnapshot	id + versión + hash del prompt usado. El texto completo vive versionado en GitHub, así se reproduce y se puede revertir
confidenceScore	Confianza del Manager (0-1) o exactitud del juez normalizada (exactitud/5). Dispara umbrales y alertas

Dimensión 3 · Gobernanza ética, ciberseguridad y compliance

Mapa de riesgos y controles configurados

Riesgo	Control que configuré	Dónde está en el flujo
1 · Alucinación destructiva (inventar plazos, reembolsos o descuentos)	RAG con Min Score + regla "No sé" + cita obligatoria. Juez con JSON Schema y regla determinista; ante una duda, CORREGIR o RECHAZADO. Batería ciega mensual	Sub-workflow RAG (M5) · §10 del prompt del Manager · SUPERVISOR_Judge + Switch (M8) · Plan de gobernanza (M5)
2 · Prompt injection (correo, chat o audio que intenta cambiar las reglas)	El contenido del usuario se trata como DATO, entre delimitadores. Instrucción explícita de ignorar órdenes embebidas. Clasificación FUERA_DE_ALCANCE. Juez con seguridad_pass. Prueba de inyección de falla controlada (QA6)	Prompt del Manager §9 (M3) · Agente de email "SEGURIDAD" (M4) · Agente de voz §5 (M6) · Juez (M8)
3 · Sesgo algorítmico en la calificación de leads	Scorecard con 4 criterios objetivos (necesidad, presupuesto, plazo, autoridad) y evidencia textual obligatoria. Prohibido puntuar por nombre, género, país, acento o tamaño de empresa. Mismo trato de "usted" y lenguaje neutro. Auditoría mensual del puntaje promedio por segmento (canal, país)	Prompt W1 / scorecard (M1, M7) · Auditor de atribución (M7) · Dashboard
4 · Acciones financieras no autorizadas	Semáforo rojo: reembolsos, precios y descuentos se congelan. Slack Send and Wait (Aprobar / Editar). Emails solo como borrador	Switch RECHAZADO → HITL (M8) · Gmail Drafts (M4) · Semáforo (M7)
5 · Fuga de datos personales y credenciales	Credenciales en el gestor cifrado de n8n con mínimo privilegio (scopes de ElevenLabs, keys separadas DEV/PROD). Audios no persistidos (Do not save + destrucción de binarios). La memoria guarda resúmenes, no transcripciones	Settings del M6 · nodos Compliance · memoria del M3 · mapa de permisos del M7

Marco ético en el System Prompt (objetividad institucional)

```
# ÉTICA Y OBJETIVIDAD (bloque común a todos los agentes de Sowe)
- Trata a todas las personas con el mismo criterio y el mismo tono (usted), sin importar nombre, género, edad,
  nacionalidad, forma de escribir o tamaño de la empresa.
- Califica solo con los criterios del scorecard y cita la evidencia textual de cada punto; sin evidencia, 0 puntos.
- No infieras datos que el usuario no dio. No opines sobre competidores ni personas.
- Si no hay base documental, responde "No sé" y deriva a un consultor: nunca adivines.
- Las decisiones de dinero, precio o compromisos contractuales no son tuyas: deriva a un humano.
```

Gobernanza de datos y privacidad empresarial

Proveedor	Plan o configuración que evita el entrenamiento con datos de Sowe	Dónde se verifica	Área a consultar en un despliegue real
OpenAI (LLM, Whisper, embeddings)	API de plataforma: por política, los datos enviados por la API no se usan para entrenar modelos (por defecto, sin opt-in). Retención de hasta 30 días para monitoreo de abuso. **Zero Data Retention** disponible para clientes elegibles, a pedido. Para escalar: ChatGPT Enterprise o Azure OpenAI con DPA	Organization Settings → Data controls (retención) en platform.openai.com · Términos de servicio y Data Processing Addendum (DPA) en openai.com/policies · página de Enterprise privacy	**Legal**: firmar el DPA y validar la transferencia internacional (Ley 25.326, AAIP). **Sistemas / Seguridad**: configurar la retención y las llaves por proyecto
Anthropic (alternativa para el juez con caché)	API comercial: los inputs y outputs no se usan para entrenar por defecto. Acuerdo de Zero Data Retention disponible para la organización. DPA comercial	Console → Settings (organización / workspaces) · Commercial Terms y DPA en anthropic.com/legal · Privacy Center	Legal + Sistemas
ElevenLabs (voz)	Planes Enterprise con Zero Retention Mode. En los planes estándar el historial de audios se guarda: se borra en la revisión mensual y solo se le envía el texto de la respuesta, nunca la voz del cliente	Settings → History / Data · Términos y DPA de ElevenLabs	Legal + Sistemas

Regla de compliance de Sowe: ningún dato personal de clientes viaja a un proveedor sin un DPA firmado. Las condiciones de retención se revisan en la auditoría trimestral junto con el plan de gobernanza del M5. Para esta entrega no se contactó a ninguna área; en un despliegue real, Legal valida los contratos y Sistemas aplica y documenta la configuración.