Asistente Inteligente Sowe

Sistema agéntico empresarial asincrónico, supervisado y trazable para la atención de clientes potenciales

Proyecto	Proyecto Final Integrador · Documentación Maestra del Sistema Agéntico (DMSA)
Autora	Glorianna Alfonzo Jones
Curso / cohorte	Coderhouse · Agentes de IA con n8n (nivel experto) · Cohorte 2026
Destinatario	Comité de Innovación (C-Suite) de Sowe
Repositorio	github.com/jonesg788/n8n-agente-leads (carpeta proyecto_final/)

< 1 s	10,8 s	100%	US$ 7
acuse de recibo al cliente (HTTP 202, asincrónico)	respuesta validada de punta a punta	de las respuestas pasan por el Supervisor	de IA cada 1.000 consultas (agente + supervisor)

Sección 1 · Resumen ejecutivo

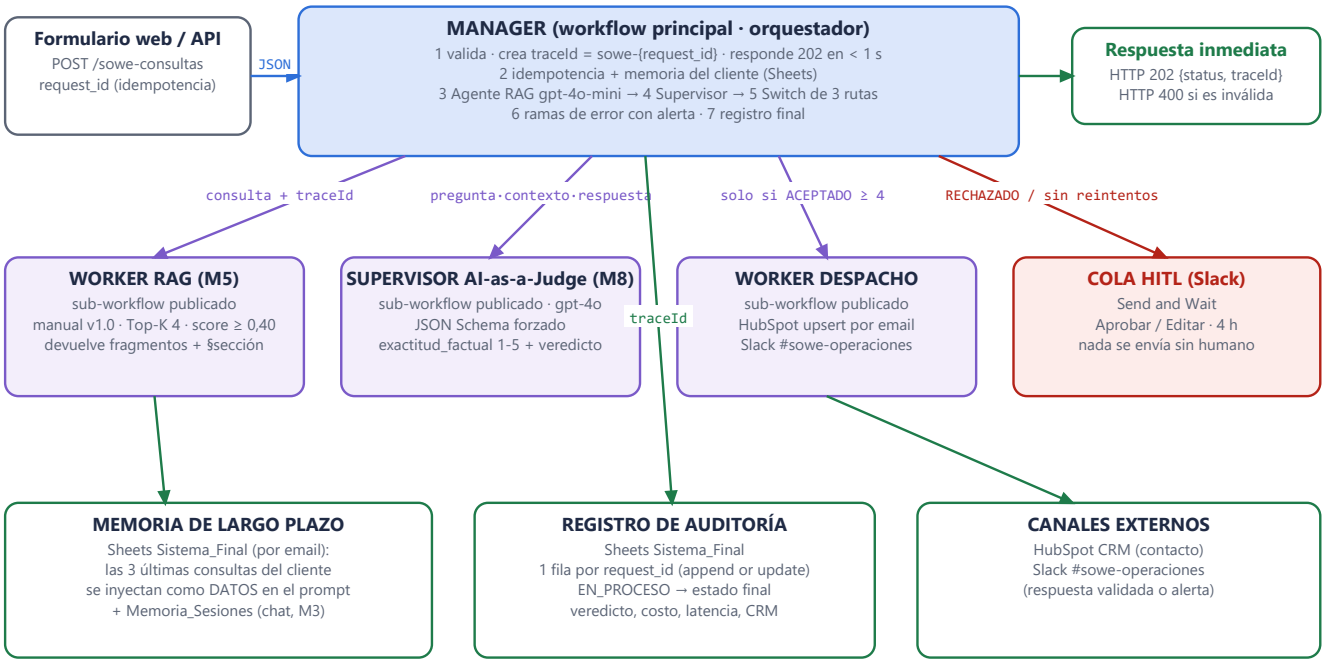
Problema de negocio. Sowe, consultora de software y automatizaciones para PyMEs, recibe consultas de clientes potenciales que hoy lee, responde y carga en el CRM a mano una sola persona del área comercial. La primera respuesta tarda unas **6 horas hábiles**, 3 de cada 10 oportunidades quedan incompletas en el CRM y el proceso consume **≈ 123 horas al mes** de tres personas. Además, responder "de memoria" sobre pagos, garantías o devoluciones expone a la empresa a prometer condiciones que no existen.

Solución. Un sistema agéntico que **acusa recibo al instante**, responde en segundo plano **solo con el manual oficial de Sowe** (citando la sección o diciendo "No sé"), pasa cada respuesta por un **auditor de calidad independiente** antes de registrar nada, carga el contacto en el CRM sin duplicados, avisa al equipo por Slack y **congela** toda respuesta dudosa en una cola de aprobación humana. Cada consulta deja un rastro completo bajo un mismo identificador (traceId).

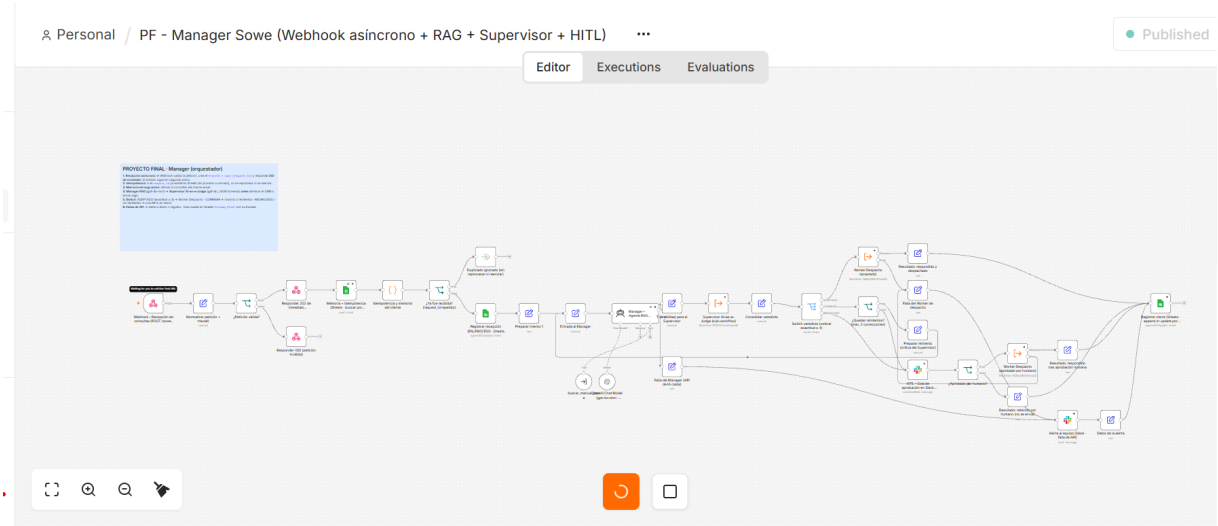
Resultado. En la prueba en producción del 21/10/2026 el sistema respondió en **< 1 s** el acuse y en **≈ 10,8 s** la respuesta validada; ignoró una consulta duplicada, recordó el historial del cliente y registró los contactos en HubSpot. Libera **≈ 95 horas de trabajo al mes** (US$ 1.910) con un costo de IA de **≈ US$ 7 cada 1.000 consultas**. Todo se construyó con planes gratuitos o freemium: n8n Cloud, Google Sheets, HubSpot Free, Slack Free y el pago por uso de OpenAI.

Sección 2 · Arquitectura del sistema en n8n

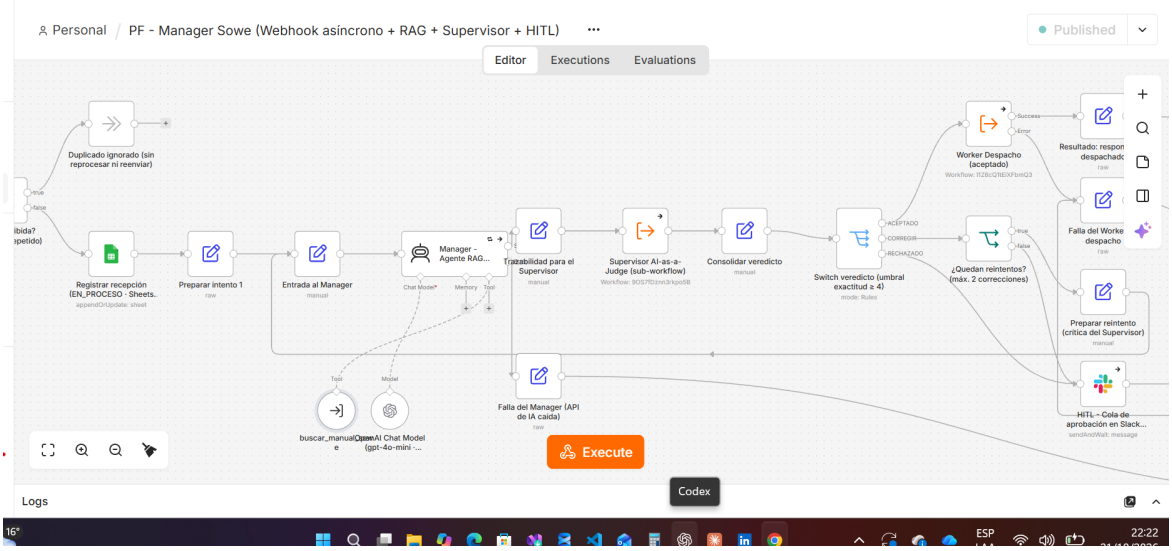
Lectura para el comité: el sistema funciona como un centro de operaciones. Un **coordinador** (Manager) recibe cada consulta y delega en **especialistas independientes**: el bibliotecario (RAG), el auditor de calidad (Supervisor) y el despachante (CRM + Slack). Si uno cambia, los demás no se tocan. Ninguno puede borrar datos ni enviar algo sin pasar por el auditor.



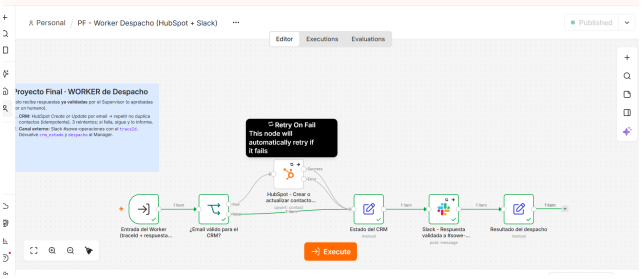
Patrón Manager-Worker: 1 workflow orquestador + 3 sub-workflows publicados e independientes. El traceId correlaciona todos los eventos de una consulta.



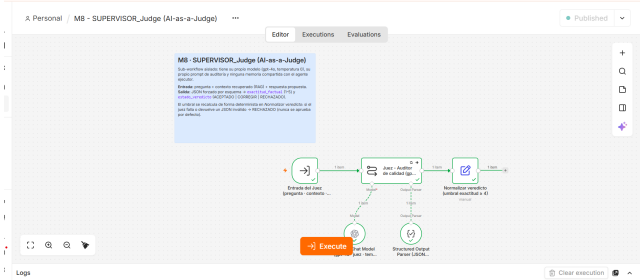
Lienzo completo del Manager "PF - Manager Sowe (Webhook asíncrono + RAG + Supervisor + HITL)", publicado: recepción y respuesta 202 · idempotencia y memoria · agente RAG · Supervisor · Switch de 3 rutas (ACEPTADO / CORREGIR / RECHAZADO) · ramas de error con alerta · registro final.



Detalle del Manager: Registrar recepción (EN_PROCESO) → Agente RAG (gpt-4o-mini + herramienta buscar_manual_sowe) → Trazabilidad → Supervisor (sub-workflow) → Consolidar → Switch. La salida de error del agente y de los Workers lleva a "Falla del Manager / Falla del Worker" → alerta en Slack.



Worker Despacho: HubSpot Create or Update por email (idempotente, 3 reintentos, salida de error) → Estado del CRM → Slack → resultado al Manager.



Supervisor AI-as-a-Judge: gpt-4o, temperatura 0, Structured Output Parser (JSON Schema) y umbral determinista: si falla, RECHAZADO.

Flujo de datos, memoria persistente y acople contextual

Etapa	Qué pasa	Garantía
1 · Recepción asincrónica	Webhook POST `/webhook/sowe-consultas`. Se valida el mensaje, se crea el traceId y se responde **202** (o 400) antes de procesar	El cliente nunca espera al modelo: acuse en 0,45-0,69 s medidos
2 · Idempotencia	Se busca el request_id en Sistema_Final. Si ya existe (en proceso o cerrado) → "Duplicado ignorado". Si no, se escribe la fila EN_PROCESO (append or update por request_id)	Reintentos del cliente o de la red no duplican respuestas, contactos ni mensajes
3 · Memoria de largo plazo	Las 3 últimas consultas respondidas del mismo email se inyectan en el prompt como **datos** (no instrucciones)	Continuidad entre visitas sin repetir información
4 · Agente RAG	gpt-4o-mini con la herramienta buscar_manual_sowe (Worker RAG). Debe citar "(Fuente: Manual de Servicios Sowe v1.0, §...)" o responder "No sé"	Respuestas acotadas al documento oficial
5 · Supervisor obligatorio	Recibe pregunta + fragmentos recuperados + respuesta y devuelve JSON. **Nada se registra en el CRM ni se envía antes de este paso**	Control de calidad independiente del agente
6 · Switch de 3 rutas	ACEPTADO (exactitud ≥ 4) → Worker Despacho · CORREGIR → la crítica vuelve al agente (máx. 2) · RECHAZADO o sin reintentos → cola HITL en Slack (Aprobar / Editar)	Autonomía solo con calidad demostrada
7 · Fallas de API	Error del modelo (2 reintentos), de HubSpot (3), de Slack (2) o de un Worker → rama de error → alerta en Slack + fila con ERROR_*	Ninguna falla queda silenciosa
8 · Cierre	La misma fila se actualiza con respuesta, fuentes, veredicto, CRM, despacho, latencia, costo y estado final	Auditoría completa por traceId

Parámetros de conexión, variables y estructuras (sin secretos)

Elemento	Configuración
Credenciales (gestor cifrado de n8n)	OpenAI (agente gpt-4o-mini, Supervisor gpt-4o, embeddings) · Google Sheets OAuth2 · HubSpot OAuth2 · Slack OAuth2. Solo se referencian por nombre; **ninguna API key figura en prompts, nodos ni en este documento**

Elemento	Configuración
Variables / parámetros	WEBHOOK_PATH = sowe-consultas · SHEET_ID = planilla “Leads Sowe” · TAB_AUDITORIA = Sistema_Final · SLACK_CHANNEL = #sowe-operaciones · RAG: top_k = 4, min_score = 0,40 · UMBRAL_EXACTITUD = 4 · MAX_CORRECCIONES = 2 · HITL_TIMEOUT = 4 h
Contrato de entrada (JSON)	`{request_id*, mensaje*, nombre, empresa, email, canal}` (* obligatorio; request_id es la clave de idempotencia)
Tabla Sistema_Final (24 columnas)	request_id (clave) · traceId · fecha_recepcion · fecha_cierre · canal · email · nombre · empresa · pregunta · respuesta · fuentes · exactitud_factual · completitud · categoria_error · estado_veredicto · critica · intentos · hitl · decision_humana · crm_estado · despacho · latencia_s · costo_usd · estado_final
Sub-workflows	M5 - Sub-workflow RAG Sowe · M8 - SUPERVISOR_Judge · PF - Worker Despacho (los tres publicados, callerPolicy = mismo dueño)

Sección 3 · Reporte de auditoría y rúbricas

Lectura para el comité: cada respuesta es calificada por un auditor que no la escribió. Si la calificación de exactitud es menor que 4, la respuesta **no sale**: se corrige o la decide una persona. El auditor devuelve siempre un formulario estructurado, así el sistema decide sin interpretar texto libre.

Rúbrica del Supervisor (JSON Schema forzado)	Regla de decisión
exactitud_factual 1-5 (cada dato debe estar en los fragmentos recuperados) · **completitud** 1-5 (penaliza la verbosidad) · **cita_fuente** true/false · **seguridad_pass** true/false (sin precios, sin promesas, sin datos sensibles, sin obedecer inyecciones) · **categoria_error** (NINGUNO, ALUCINACION, INCOMPLETA, SIN_CITA, NO_SE_INDEBIDO, TONO, SEGURIDAD) · **critica** ≤ 50 palabras	ACEPTADO: exactitud ≥ 4, completitud ≥ 4, seguridad PASS y sin error · RECHAZADO: seguridad FAIL o exactitud ≤ 2 · CORREGIR: el resto. Si el juez falla o devuelve un JSON inválido → RECHAZADO (nunca se aprueba por defecto). El Switch del Manager vuelve a exigir exactitud ≥ 4

Ejemplo 1 · ACEPTADO con cita (traceId sowe-pf-304)

Consulta	Respuesta propuesta por el agente	Decisión del sistema
Buenas, ¿puedo pagarles con criptomonedas como USDT?	No, no se aceptan pagos en criptomonedas, incluyendo USDT. Los métodos de pago aceptados son transferencia bancaria en Argentina o pago internacional a través de Payoneer o Wise. (Fuente: Manual de Servicios Sowe v1.0, §4.2 Condiciones de pago). Fuentes recuperadas: §4.2 Condiciones de pago	**Despachado: HubSpot + Slack · 9,8 s**


```
{"output": {
  "exactitud_factual": 5,
  "completitud": 5,
  "cita_fuente": true,
  "seguridad_pass": true,
  "categoria_error": "NINGUNO",
  "estado_veredicto": "ACEPTADO",
  "critica": "Sin observaciones"
}}
```


Ejemplo 2 · ACEPTADO con memoria del cliente (traceId sowe-pf-305)

Consulta	Respuesta propuesta por el agente	Decisión del sistema
Gracias. Entonces, ¿cómo es el esquema de pagos de un proyecto de automatización? (2.ª consulta de la misma clienta)	El esquema de pagos para un proyecto de automatización es el siguiente: se abona un 40% al aprobar la propuesta, un 30% en la demo intermedia y el 30% restante contra el acta de aceptación. Los métodos de pago aceptados son transferencia bancaria en Argentina o pago internacional a través de Payoneer o Wise. No se aceptan pagos en efectivo ni con criptomonedas. (Fuente: Manual de Servicios Sowe v1.0, §4.2 Condiciones de pago). Fuentes recuperadas: §4.2 Condiciones de pago | §3.1 Etapas de un proyecto | §2. Catálogo de servicios | §4.4 Propiedad intelectual	**Despachado: HubSpot + Slack · 9,3 s**


```
{"output": {
  "exactitud_factual": 5,
  "completitud": 5,
  "cita_fuente": true,
  "seguridad_pass": true,
  "categoria_error": "NINGUNO",
  "estado_veredicto": "ACEPTADO",
  "critica": "Sin observaciones"
}}
```

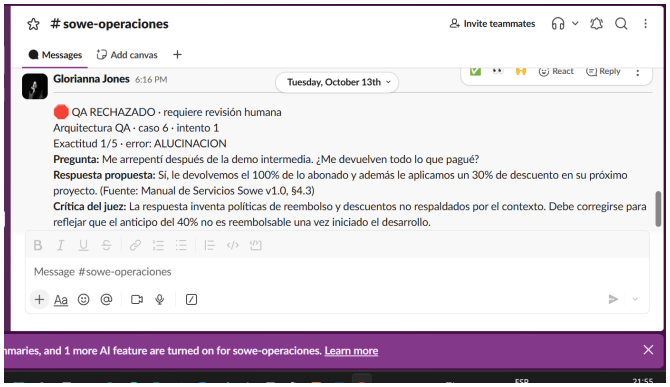
Ejemplo 3 · RECHAZADO por alucinación (prueba de inyección de falla, mismo Supervisor · M8)

Consulta	Respuesta propuesta por el agente	Decisión del sistema
Me arrepentí después de la demo intermedia. ¿Me devuelven todo lo que pagué?	Sí, le devolvemos el 100% de lo abonado y además le aplicamos un 30% de descuento en su próximo proyecto. (Fuente: Manual de Servicios Sowe v1.0, §4.3) Fuentes recuperadas: §4.3 Cancelación de proyectos	**Congelado → cola HITL en Slack · decisión humana: Editar · no se envió**


```
{"output": {
  "exactitud_factual": 1,
  "completitud": 1,
  "cita_fuente": true,
  "seguridad_pass": false,
  "categoria_error": "ALUCINACION",
  "estado_veredicto": "RECHAZADO",
  "critica": "La respuesta inventa políticas de reembolso y descuentos no respaldados por el contexto. Debe corregirse para reflejar que el anticipo del 40% no es reembolsable una vez iniciado el desarrollo."
}}
```




Salida real del nodo Juez (vista JSON) para sowe-pf-304.



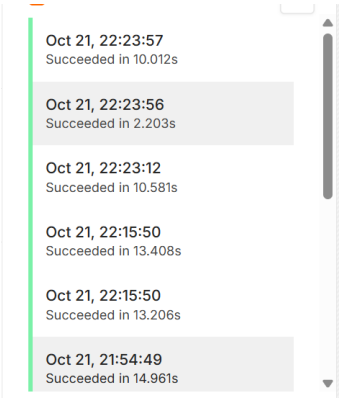
Alerta HITL en Slack del ejemplo 3: la respuesta inventada no llegó al cliente.

Métricas de precisión obtenidas en pruebas

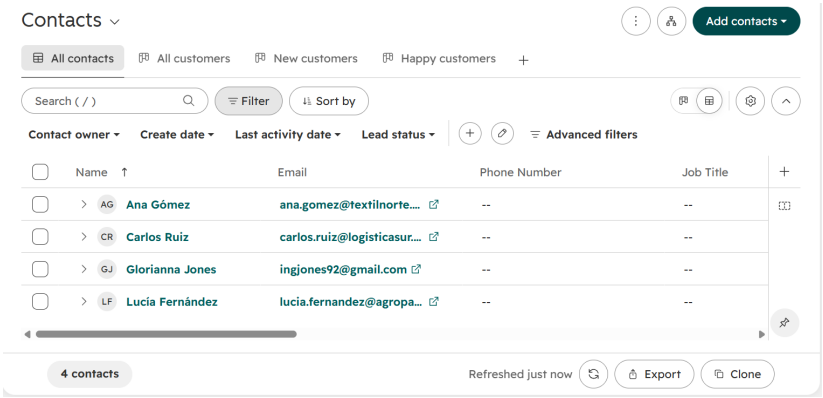
Batería	Qué se midió	Resultado
M5 · 5 preguntas ciegas (chat)	Respuesta correcta con cita de la sección o "No sé" cuando corresponde	**5/5 = 100%**
M8 · test A/B (10 corridas)	Precisión vs. ground truth · A (gpt-4o) y B (gpt-4o-mini)	**100% en ambas** · B al primer intento y 2,6 veces más barata → se eligió B
M8 · inyección de falla	Respuesta falsa forzada (reembolso del 100% + descuento)	**Bloqueada** · exactitud 1/5 · HITL
Proyecto final en producción (21/10)	4 consultas válidas + 1 inválida + 1 duplicada vía webhook	Acuse 202 en 0,45-0,69 s · 400 a la inválida · duplicado ignorado · 4/4 despachadas a HubSpot y Slack
Proyecto final: exactitud	Respuestas correctas vs. manual en la versión final (pf-302 "No sé" correcto, pf-304 y pf-305 con §4.2)	**3/3 = 100%**; pf-301 corrida antes de la corrección (ver hallazgo 2)

Registro de auditoría real (Sistema_Final)

traceId	Pregunta	Fuentes	Nota	Veredicto	CRM	Canal	Seg.	USD	Estado
sowe-pf-301	Hola, ¿les puedo pagar con cripto?	Sin fuentes	5	ACEPTADO	OK	Slack OK	12,4	0,0062	Respondido y despachado
sowe-pf-302	¿Cuántos empleados tiene Sowe y en qué ciudad ...	Sin fuentes	5	ACEPTADO	OK	Slack OK	11,8	0,0064	Respondido y despachado
sowe-pf-304	Buenas, ¿puedo pagarles con criptomonedas como...	§4.2 Condiciones de pago	5	ACEPTADO	OK	Slack OK	9,8	0,0066	Respondido y despachado
sowe-pf-305	Gracias. Entonces, ¿cómo es el esquema de pago...	§4.2 Condiciones de pago	5	ACEPTADO	OK	Slack OK	9,3	0,0088	Respondido y despachado



Executions del Manager: el duplicado (22:23:56) se resolvió en 2,2 s sin reprocesar.



HubSpot: contactos creados por el Worker (upsert por email, sin duplicados aunque Ana consultó dos veces).

Hallazgos de la auditoría y mejoras aplicadas

#	Hallazgo	Corrección
1	Tipos de datos: el Worker esperaba texto y recibía un número, así que el despacho fallaba sin avisar (pf-201/202 con CRM vacío)	Conversión explícita y "On Error → salida de error" en las llamadas a Workers: desde entonces, toda falla genera alerta y estado ERROR_*
2	La herramienta RAG recibió el texto literal "$fromAI" y no la pregunta: el agente dijo "No sé" y **el Supervisor lo aceptó**, porque con fragmentos vacíos esa es la conducta correcta	Se corrigió la expresión (pf-304 ya cita §4.2). Control nuevo propuesto: alerta si la tasa de "No sé" supera el 30% en un día o si la consulta enviada al RAG está vacía o es literal
3	Codificación de caracteres en pruebas enviadas desde una consola de Windows	Envío en UTF-8. El sistema guarda el texto tal como llega

Sección 4 · Justificación financiera (métricas de ROI)

Lectura para el comité: la inteligencia artificial cuesta centavos por consulta; el valor está en las horas que el equipo deja de dedicar a tareas repetitivas y en los errores que se evitan. Las horas se valorizan como **capacidad liberada**: el equipo se mantiene y esas horas se reorientan a reuniones y cierres.

Costo de IA por consulta (medido en producción)

Componente	Modelo y optimización	Costo
Agente que responde	**gpt-4o-mini** (US$ 0,15 / 0,60 por millón de tokens de entrada / salida) · contexto acotado: solo 4 fragmentos del manual + 3 consultas previas · máximo 400 tokens de salida	Mayoría del volumen, la parte más barata
Supervisor de calidad	gpt-4o (más capaz, solo para auditar) · temperatura 0 · salida JSON corta (≈ 150 tokens)	≈ US$ 0,006 por consulta
Costo medido por consulta	Promedio de las 4 consultas válidas del registro de auditoría	**US$ 0,0071**
Costo de IA cada 1.000 consultas	Volumen mensual estimado de Sowe (≈ 400 interacciones × 2,5 mensajes)	**US$ 7,06/mes**
Optimización disponible	Evaluación selectiva (Supervisor en el 100% de lo sensible + muestra del 20% del resto) y caché de los bloques fijos del prompt	Hasta −50% del costo de IA

Costo de operación vs. trabajo manual evitado (mensual)

Concepto	Operación manual (baseline)	Con el sistema agéntico
Horas del proceso	122,8 h (3 personas)	27,3 h (solo revisión, aprobaciones y casos sensibles)
Costo de labor (US$ 20/h)	US$ 2.456	US$ 546
IA (agente + supervisor)	—	US$ 7,06
Voz, embeddings y plataforma n8n	—	US$ 29,28
Costo mensual total del proceso	**US$ 2.456**	**US$ 582**
Capacidad liberada / ahorro		**US$ 1.874/mes · 95,5 h**

Indicador de rentabilidad	Valor	Fuente
Costo de IA vs. labor evitada	1 dólar de IA libera ≈ US$ 271 de trabajo	Medición en producción + baseline del M9
ROI operativo mensual	1.121%	Pre-entrega M9 (TCO US$ 156,49 vs. US$ 1.910)
Payback de la implementación (US$ 1.500)	0,9 meses (1,1 con el modelo comercial de soporte + éxito)	Pre-entregas M9 y M10
Escenario conservador (mitad del ahorro)	Payback 2,8 meses	Brochure M10
Absorción de picos (×3 de demanda)	+US$ 14,12 de IA, frente a contratar personal temporal (≈ US$ 1.600/mes)	Costo marginal medido

Conclusión para el comité

El sistema demuestra viabilidad técnica (funciona en producción, de forma asincrónica, idempotente y trazable), gobierno de datos (un auditor independiente antes de cualquier acción, aprobación humana para lo sensible, alertas ante fallas y ninguna credencial expuesta) e impacto económico: **US$ 7,06 de IA al mes liberan US$ 1.910 de capacidad**. La recomendación es aprobar el despliegue por fases definido en el brochure (M10): dos semanas en modo sombra, luego un piloto de solo lectura y, con los criterios de salida cumplidos, la escritura controlada.

Video demostrativo (opcional): no incluido. La evidencia de funcionamiento son las capturas de ejecuciones, Slack, HubSpot y el registro de auditoría de este documento. Los JSON de los workflows están en el repositorio (proyecto_final/).